



Universidade Federal da Paraíba
Centro de Energias Alternativas e Renováveis
Departamento de Engenharia Elétrica
Disciplina de Automação Inteligente

Miguel Marques Ferreira

Rafael Pereira do Nascimento

Orientador: Prof. Dr. Juan Moises Mauricio Villanueva

Sistema Fuzzy para Controle um Sistema de Bombeamento de Água Avaliação 02



João Pessoa - PB

Março, 2024

Miguel Marques Ferreira
Rafael Pereira do Nascimento
Orientador: Prof. Dr. Juan Moises Mauricio Villanueva

**Sistema Fuzzy para Controle um Sistema de
Bombeamento de Água
Avaliação 02**

Relatório técnico apresentado como requisito
parcial para aprovação na disciplina de Auto-
mação Inteligente, graduação em Engenharia
Elétrica.

Universidade Federal da Paraíba – UFPB
Centro de Energias Alternativas e Renováveis – CEAR
Departamento de Engenharia Elétrica – DEE
Disciplina de Automação Inteligente

João Pessoa - PB
Março, 2024

Sumário

1	INTRODUÇÃO	3
2	DESENVOLVIMENTO	4
2.1	Modelagem da planta	4
2.1.1	Rede neurais artificiais	4
2.2	Controlador Fuzzy	6
2.3	Interface	10
3	RESULTADOS E DISCUSSÃO	13
4	CONCLUSÃO	15

1 Introdução

A aplicação da lógica fuzzy para o controle de sistemas tem se destacado como uma abordagem poderosa e flexível em uma variedade de campos, desde engenharia e automação industrial até sistemas de suporte à decisão e inteligência artificial.

Nessa conjuntura, a lógica fuzzy fornece uma estrutura matemática que lida com a incerteza e a imprecisão de forma mais natural do que a lógica binária ou booleana convencional. Isso permite a modelagem de sistemas complexos e a tomada de decisões em situações onde as informações disponíveis são vagas ou ambíguas.

Além disso, existem aplicações de lógica fuzzy em projetos de controladores que podem lidar eficazmente com sistemas dinâmicos não lineares e imprevisíveis. Ao combinar a teoria da lógica fuzzy com técnicas de controle clássicas ou modernas, é possível desenvolver sistemas de controle robustos e adaptativos que conseguem enfrentar os desafios encontrados em ambientes reais e variáveis.

Neste trabalho, serão explorados os fundamentos da lógica fuzzy e redes neurais, em que se modelou um sistema de abastecimento de água que bombeia o fluido para duas regiões com diferentes topologias: a Zona Alta e a Zona Baixa. Este sistema é composto por um conjunto motor-bomba (CMB), um booster (BST), canos, dois reservatórios, sensores de pressão e vazão, além de válvulas redutoras proporcionais (VRP). Utilizando redes neurais para modelar o sistema, foi possível implementar um controle inteligente utilizando a lógica fuzzy.

Ademais, esta atividade consiste na avaliação da segunda unidade da disciplina de Automação Inteligente do curso de Engenharia Elétrica na Universidade Federal da Paraíba (UFPB).

2 Desenvolvimento

Inicialmente, houve a necessidade de reproduzir o sistema de bombeamento de água para, posteriormente, realizar a concepção do controlador fuzzy. Dessa forma, modelou-se o sistema para que, a partir de novos valores de entrada, o valor da pressão no ponto PT-2 fosse estimado.

2.1 Modelagem da planta

Para a construção do modelo, coletamos informações de pressão com base nos valores de abertura da válvula e na frequência do motor. Essa coleta foi realizada para os seguintes ângulos de abertura da válvula: 0, 30, 60 e 70. Analogamente, testamos a operação do sistema para diferentes frequências de operação do CMB, variando de 30 a 60 Hz em incrementos de 5 Hz, inicialmente, e depois alterando a frequência para valores não múltiplos de 5 a fim de construir um conjunto de dados para avaliação do modelo da planta. Com base nos dados coletados, foi desenvolvido um modelo baseado redes neurais artificiais (RNA).


2.1.1 Rede neurais artificiais

O processo de desenvolvimento do modelo iniciou-se a partir da identificação e seleção das variáveis mais relevantes para a modelagem, isto é, variáveis que possui maior correlação com a saída desejada em pressão (M.C.A). Assim, utilizando a técnica SelectKBest da biblioteca scikit-learn, mantivemos apenas as características essenciais, incluindo Frequência, Ângulo da Válvula, bem como valores de pressão anteriores em 1 e 2 segundos como PT-2 (K-1) e PT-2 (K-2), respectivamente. Esta etapa foi crucial para reduzir a dimensionalidade dos dados e melhorar a eficiência do modelo.

Após o pré-processamento, dividimos o conjunto de dados em conjuntos de treinamento e teste, esses ilustrados nas [Figura 1](#) e [Figura 2](#). Percebe-se que os dados de treinamento consiste no conjunto de dados coletados para frequências múltiplas de 5 Hz, enquanto o conjunto de testes reúne os dados coletados para frequências não múltiplas de 5 Hz.


No entanto, para uma avaliação mais precisa do desempenho do modelo, também separamos uma porção dos dados de treinamento para formar um conjunto de validação. Esta prática é fundamental para ajustar os hiperparâmetros do modelo e evitar o falhas no aprendizado do modelo.

Figura 1 – Dados de teste.



Fonte: Autoria própria.

Figura 2 – Dados de treino.

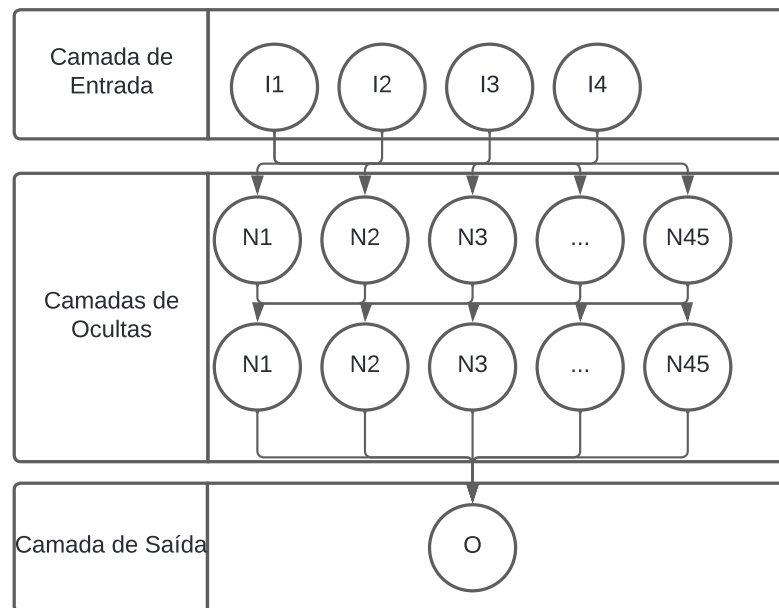


Fonte: Autoria própria.

A seguir, implementamos o modelo baseado em RNA para o controle da planta de

abastecimento. O modelo consiste em uma arquitetura com 4 neurônios de entrada, duas camadas ocultas, cada uma com 45 neurônios, e uma camada de saída, o diagrama do modelo pode ser visto [Figura 3](#). Esta configuração foi escolhida com base na complexidade do problema e experimentos anteriores.

Figura 3 – Diagrama da rede neural.



Fonte: Autoria própria.

Para evitar o excesso de aprendizado por parte do modelo, incorporamos a técnica de early stopping durante o treinamento da RNA, a qual consiste em interromper o treinamento quando não há mais melhorias significativas no desempenho do modelo sobre o conjunto de validação. Isso ajuda a garantir que o modelo generalize bem para novos dados, bem como diminui o tempo na etapa de desenvolvimento da rede.

Na etapa de validação, a saída prevista do modelo pode ser vista pela [Figura 4](#).


Tabela 1 – Métricas de erro para o modelo da planta baseado em RNA.

MAE	MSE	RMSE	MAPE	ERPM
0.0848	0.0224	0.1495	0.7029	17.3776

2.2 Controlador Fuzzy

Para garantir a eficiência do sistema, será empregado um controlador fuzzy, cujo objetivo principal é manter a pressão no ponto PT-2 da rede de abastecimento de água nos

Figura 4 – Gráfico com o valor de pressão real e previsto pela RNA.



Fonte: Autoria própria.

níveis ideais. Na modelagem desse sistema de controle, as entradas são o erro da pressão (a diferença entre o valor desejado e o valor medido da pressão) e a derivada desse erro, representadas como E e ΔE , respectivamente.


Para ambas as variáveis, E e ΔE , serão utilizados cinco conjuntos de pertinência na composição das funções de pertinência. O conjunto E abrangerá a faixa de valores de pressão entre -15 e 15 M.C.A, enquanto o conjunto ΔE será mais restrito devido à alta frequência de amostragem, delimitado entre -5 e 5 Hz.

O controlador fuzzy produzirá uma única saída, denominada delta de frequência (ΔF), que estará diretamente associada à pressão. Essa saída indicará uma variação positiva ou negativa somada a frequência de operação do CBM. Logo, um incremento negativo sugerirá que a pressão está acima do valor de referência, sendo necessário um menor esforço do CBM e um menor gasto de potência elétrica, enquanto um incremento positivo indicará que a pressão medida está abaixo da referência, indicando a necessidade um maior esforço do CBM e, conseqüentemente, um maior consumo de potência elétrica pelo equipamento.

Uma vez identificada as variáveis linguísticas, desenvolveram-se as funções de pertinências com seus respectivos universos de discursos e seus valores linguísticos, que podem ser visto na [Figura 5](#).

Para a variável E , foram associadas cinco funções de pertinência distintas para capturar diferentes cenários de erro de pressão. As funções EGN (erro grande negativo) e EGP (erro grande positivo) representam uma diferença significativa, seja positiva ou

Figura 5 – Função de pertinência das variáveis de entrada e saída.



Fonte: Autoria própria.

negativa, entre o valor medido e o valor desejado da pressão. Por outro lado, as funções EN (erro negativo) e EP (erro positivo) descrevem diferenças menos acentuadas em comparação às anteriores. Finalmente, a função EZ (erro zero) é acionada quando o valor medido da pressão é igual ao valor desejado.

Para a variável ΔE , foram atribuídas cinco funções de pertinência para abranger diferentes cenários de mudança na pressão. A função DEGN (derivada do erro grande negativo) indica uma diminuição rápida na pressão, enquanto a função DEN (derivada do erro negativo) representa uma diminuição menos acentuada. A função DEZ (zero derivada da pressão) indica estabilização no valor. Por outro lado, a função DEP (derivada do erro positivo) indica um aumento na pressão, e a função DEGP (derivada do erro grande positiva) descreve um aumento rápido na pressão.

Por fim, para a variável ΔF , foram definidas cinco funções de pertinência para representar diferentes comportamentos na frequência. A função DFGN (derivada da frequência grande negativa) proporciona ao sistema um grande decréscimo na frequência, enquanto DFN (derivada da frequência negativa) resulta em um decréscimo na frequência.

DFZ (zero derivada da frequência) mantém a atual igual à anterior, indicando estabilidade. Por outro lado, a função DFP (derivada da frequência positiva) proporciona um aumento na frequência, e DFGP (derivada da frequência grande positiva) promove um grande incremento na frequência. Essas funções de pertinência são essenciais para o correto funcionamento e adaptação do controlador fuzzy ao ambiente operacional.


Após a definição das funções de pertinência e seus termos linguísticos correspondentes, o próximo passo foi estabelecer as regras fuzzy que guiarão o funcionamento do controlador. Considerando a relação entre a pressão do sistema e a frequência de controle do motor, inicialmente foram formuladas 25 regras para governar o comportamento do sistema. A [Tabela 2](#) apresenta as regras utilizadas para a inferência fuzzy de Mamdani especificadas para o controlador. Além disso, o método de defuzzificação escolhido foi o centro de máximo.

Tabela 2 – Conjunto de regras utilizadas para treinar o sistema fuzzy.

1ª Condicional	Op. Lógico	2ª Condicional	Resultado
Erro IS EGN	AND	derivadaErro IS DEGN	deltaFrequencia IS DFN
Erro IS EGN	AND	derivadaErro IS DEN	deltaFrequencia IS DGFN
Erro IS EGN	AND	derivadaErro IS DEZ	deltaFrequencia IS DGFN
Erro IS EGN	AND	derivadaErro IS DEP	deltaFrequencia IS DGFN
Erro IS EGN	AND	derivadaErro IS DEGP	deltaFrequencia IS DGFN
Erro IS EN	AND	derivadaErro IS DEGN	deltaFrequencia IS DFN
Erro IS EN	AND	derivadaErro IS DEN	deltaFrequencia IS DFN
Erro IS EN	AND	derivadaErro IS DEZ	deltaFrequencia IS DFN
Erro IS EN	AND	derivadaErro IS DEP	deltaFrequencia IS DFN
Erro IS EN	AND	derivadaErro IS DEGP	deltaFrequencia IS DFGN
Erro IS EZ	AND	derivadaErro IS DEGN	deltaFrequencia IS DFZ
Erro IS EZ	AND	derivadaErro IS DEN	deltaFrequencia IS DFZ
Erro IS EZ	AND	derivadaErro IS DEZ	deltaFrequencia IS DFZ
Erro IS EZ	AND	derivadaErro IS DEP	deltaFrequencia IS DFZ
Erro IS EZ	AND	derivadaErro IS DEGP	deltaFrequencia IS DFZ
Erro IS EP	AND	derivadaErro IS DEGN	deltaFrequencia IS DFGP
Erro IS EP	AND	derivadaErro IS DEN	deltaFrequencia IS DFP
Erro IS EP	AND	derivadaErro IS DEZ	deltaFrequencia IS DFP
Erro IS EP	AND	derivadaErro IS DEP	deltaFrequencia IS DFP
Erro IS EP	AND	derivadaErro IS DEGP	deltaFrequencia IS DFP
Erro IS EGP	AND	derivadaErro IS DEGN	deltaFrequencia IS DFGP
Erro IS EGP	AND	derivadaErro IS DEN	deltaFrequencia IS DFGP
Erro IS EGP	AND	derivadaErro IS DEZ	deltaFrequencia IS DFGP
Erro IS EGP	AND	derivadaErro IS DEP	deltaFrequencia IS DFGP
Erro IS EGP	AND	derivadaErro IS DEGP	deltaFrequencia IS DFP

A representação gráfica na [Figura 10](#) apresenta a superfície de controle adotada, a qual integra o E , ΔE e ΔF em cada eixo da figura 3D a seguir.

Figura 6 – Superfície fuzzy de regras.



Fonte: Autoria própria.

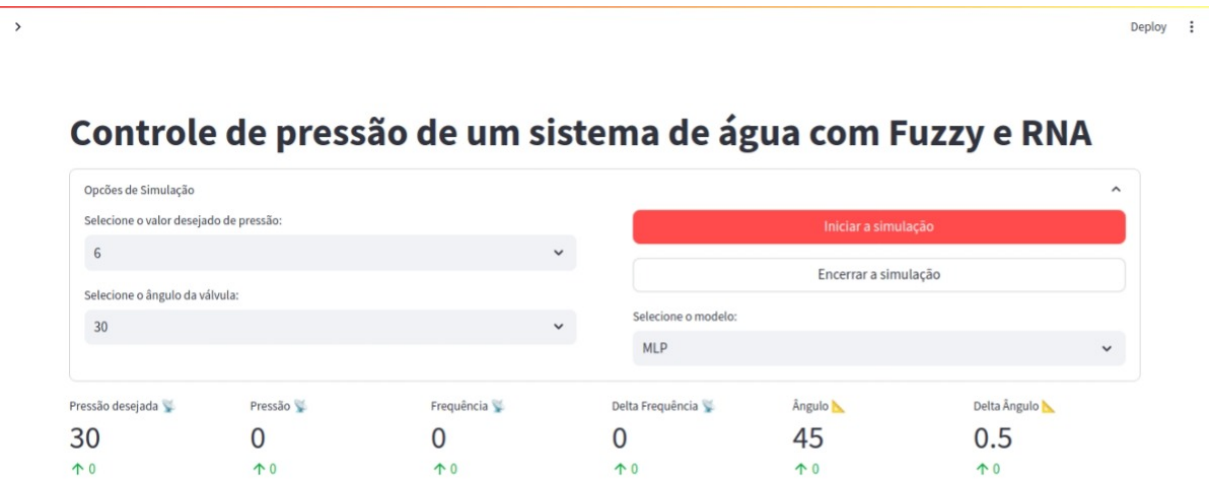
2.3 Interface

Por fim, foi desenvolvida um painel de controle com a linguagem de programação Python para promover a visualização e interação com o sistema de controle desenvolvido neste trabalho.

A apresentação de dados pelo painel de controle seguiu a ordem de receber o valor desejado de pressão do usuário, comparar com o valor atual de pressão na saída do sistema e, assim, calcular o erro e o delta do erro. Logo após, ocorre a ingestão desses dados pelo controlador fuzzy, o qual alimenta o modelo da planta com a variação de frequência

necessária para minimizar o erro entre valor desejado e real para a variável de pressão na saída do sistema de bombeamento de água.

Figura 7 – Página principal do painel de controle do sistema de bombeamento de água.



Fonte: Autoria própria.

Figura 8 – Página principal do painel de controle com início da simulação.



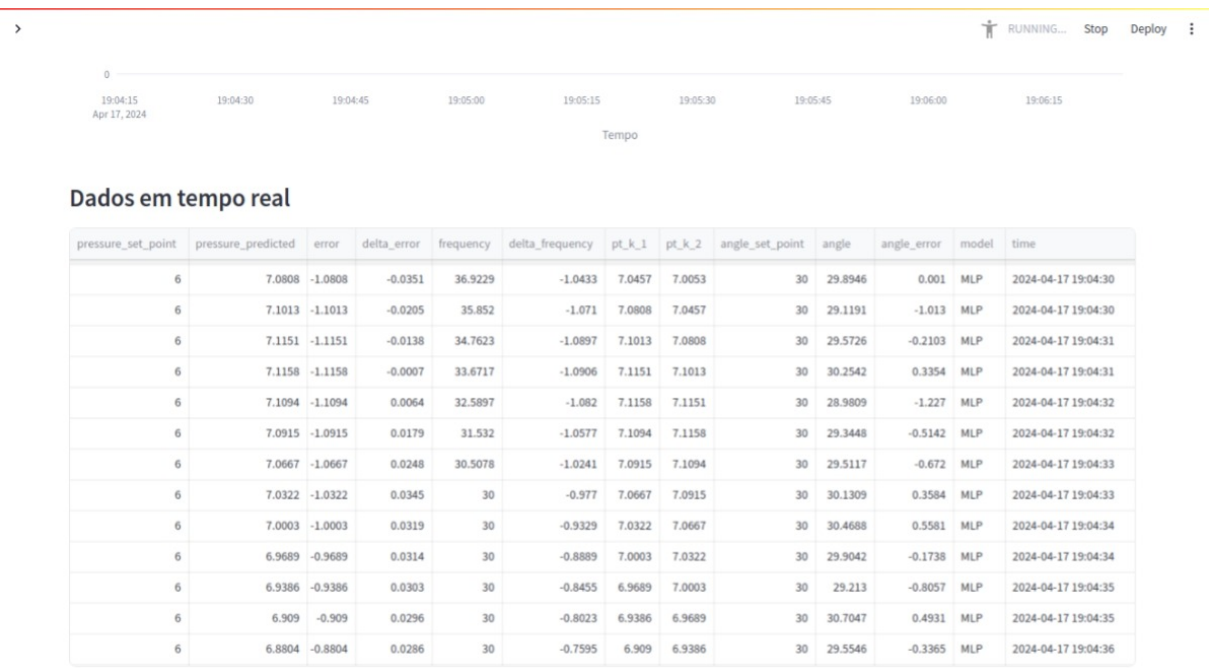
Fonte: Autoria própria.

Figura 9 – Página principal do painel de controle com informações de frequência do CBM.



Fonte: Autoria própria.

Figura 10 – Página principal do painel de controle com detalhes dos valores em tempo real.

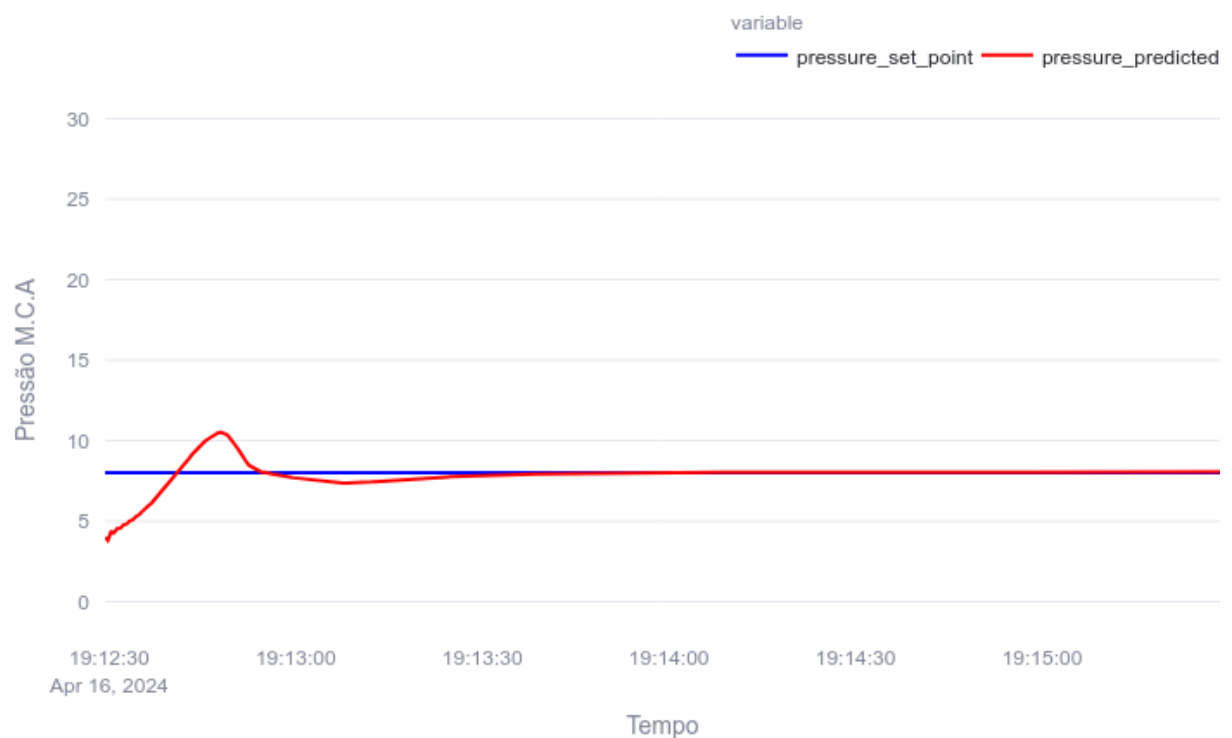


Fonte: Autoria própria.

3 Resultados e Discussão

O desempenho do controlador foi notavelmente eficiente na manutenção da pressão em 6 M.C.A, valor inicialmente adotado para os testes. Além de enfrentar mudanças no consumo, o sistema foi submetido a diversas perturbações, variação da válvula de saída de água, ilustradas na [Figura 11](#).

Figura 11 – Resposta do sistema para pressão desejada de 6 M.C.A e 30° de abertura da válvula.



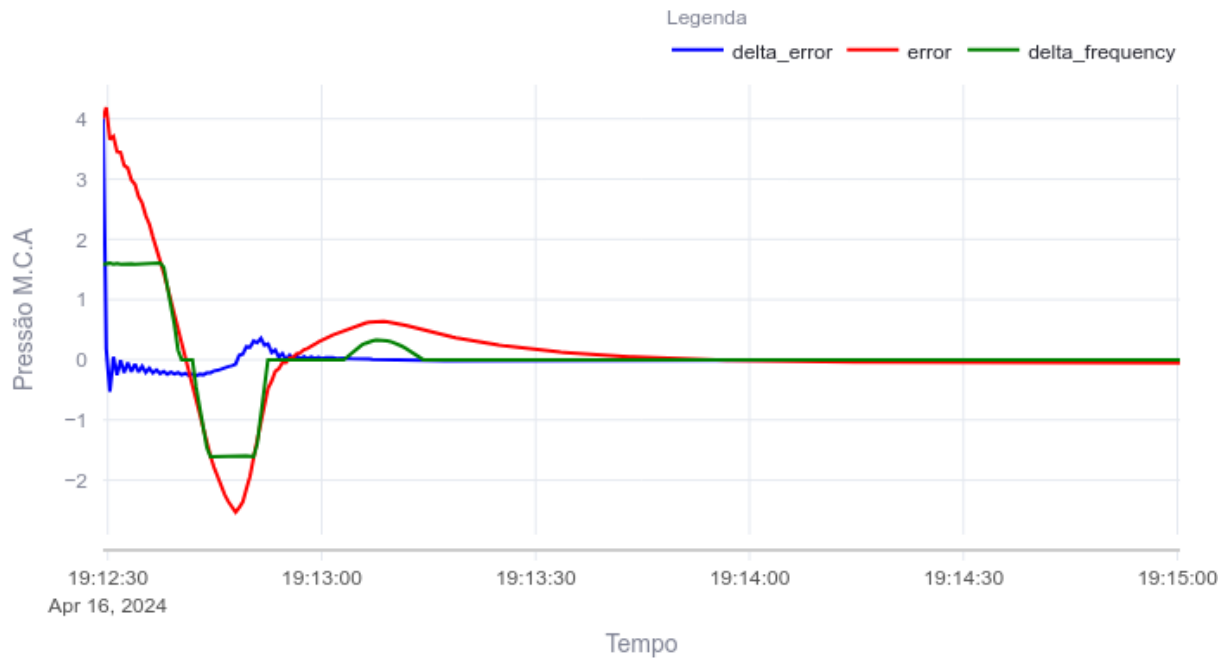
Fonte: Autoria própria.

Analisando os gráficos na [Figura 11](#), observamos que essas perturbações não tiveram impacto significativo e a pressão medida se manteve próxima à pressão de referência. Além do excelente desempenho do controlador diante dos diferentes cenários de consumo, o sistema em malha fechada demonstrou eficácia ao lidar com as perturbações apresentando um tempo de assentamento próximo dos 30 segundos, um erro em regime estacionário inferior a 0.8 M.C.A e um sobrevalor inferior a 2.1 M.C.A.

Além disso, na [Figura 12](#), destaca-se a ocorrência de saturação na saída do controlador fuzzy, especialmente para valores desejados de pressão abaixo de 3 M.C.A e superior a 12 M.C.A, indicando a necessidade de analisar a faixa das variáveis de entrada e revisar


as regras do sistema fuzzy.

Figura 12 – Erros utilizados pelo sistema para pressão desejada de 6 M.C.A e 30° de abertura da válvula.



Fonte: Autoria própria.

Figura 13 – Frequência do CMB para operação do sistema com pressão desejada de 6 M.C.A e 30° de abertura da válvula.



Fonte: Autoria própria.

4 Conclusão

O controlador foi projetado com base em regras empiricamente e teoricamente comprovadas. Após a sua implementação, foram conduzidos experimentos para verificar sua capacidade de manter a pressão constante em diferentes cenários de consumo e analisar suas características. Além disso, foram examinados os valores de potência requerida do motor em operação de malha aberta e fechada, a fim de avaliar a eficiência energética.

Os resultados dos experimentos revelaram que o uso do controlador fuzzy foi satisfatório, mantendo a pressão próxima do valor de referência em diferentes cenários de consumo e diante de perturbações simuladas na planta. O erro percentual no regime estacionário foi de apenas 1,33%.