



CEAR

CENTRO DE ENERGIAS
ALTERNATIVAS E RENOVÁVEIS
UNIVERSIDADE FEDERAL DA PARAÍBA




Introdução aos Algoritmos Genéticos

Prof. Flavio da Silva Vitorino Gomes

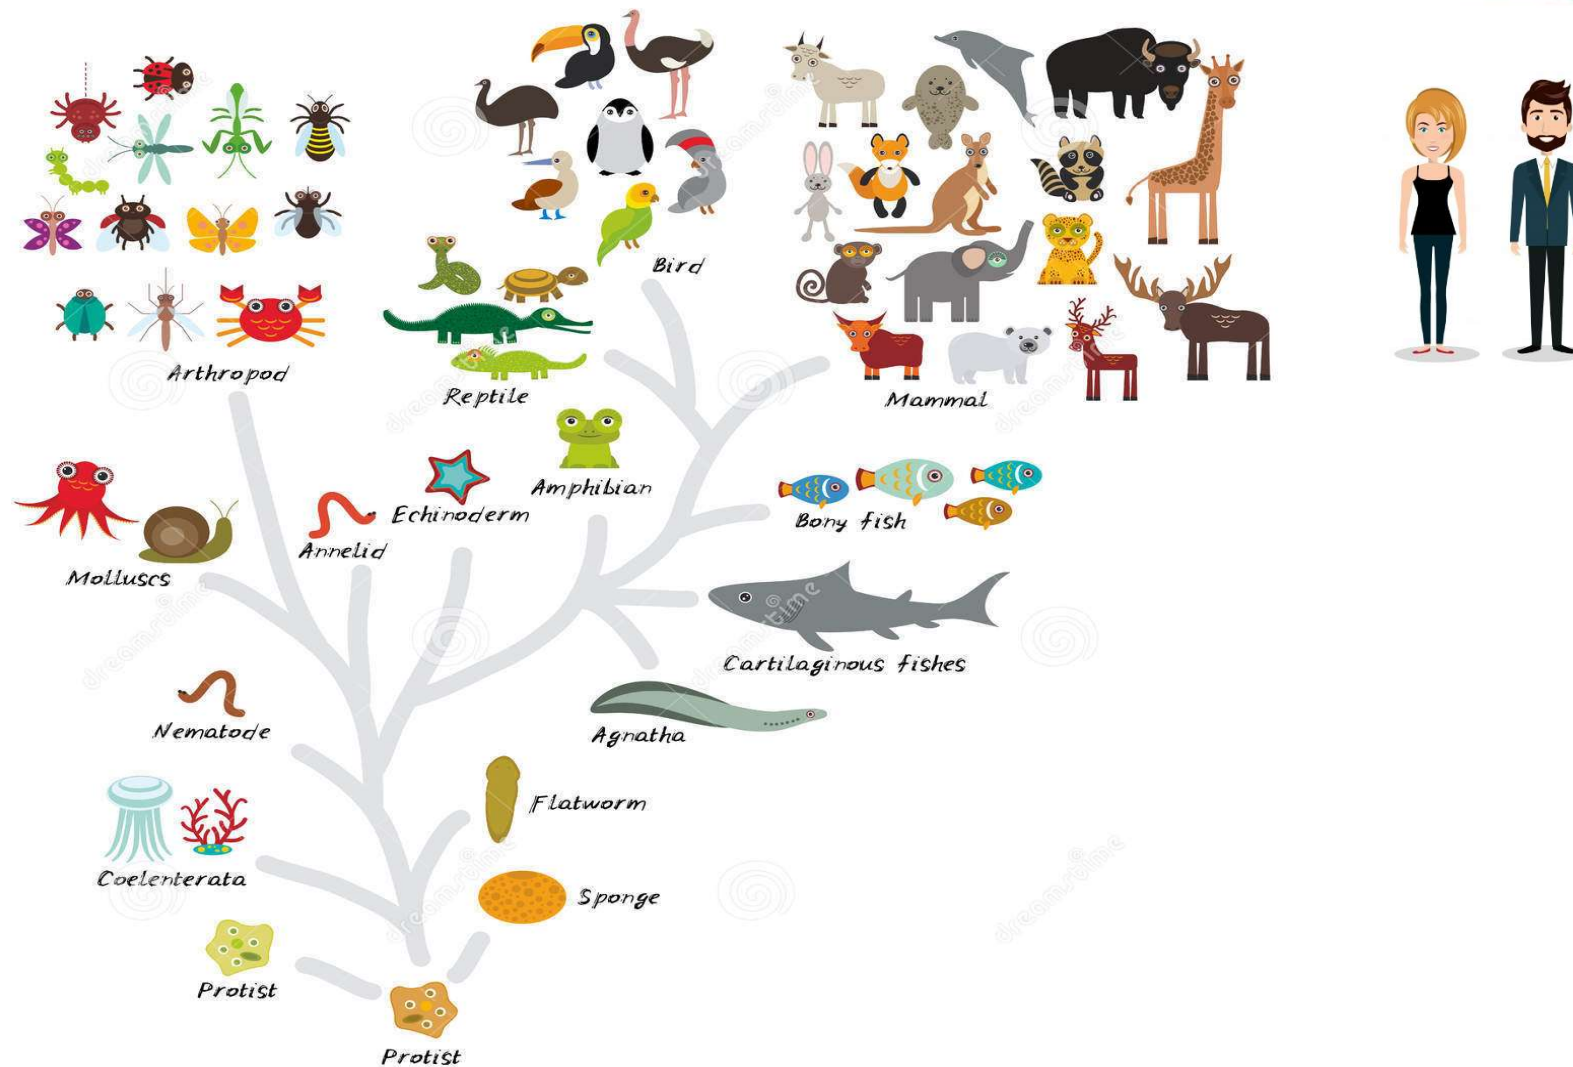
Criacionismo x Evolucionismo



A Criação de Adão
(Michelangelo, 1511)



A Evolução na Biologia




A Teoria da Evolução



Em 1859, Charles Darwin apresentou sua teoria de evolução através de seleção natural.

Introduziu a ideia de evolução a partir de um ancestral comum, por meio de seleção natural.



“Não é o mais forte que sobrevive, nem o mais inteligente, mas o que melhor se adapta às mudanças.”

Leon C. Megginson, professor da Louisiana State University, num discurso em 1963, onde apresenta a sua interpretação da ideia central de "A Origem das Espécies" de Charles Darwin.

A Teoria da Evolução



Darwin consciente das implicações de seu trabalho sobre a tese da imutabilidade das espécies e preceitos religiosos, metódica e minuciosamente junta, durante uma viagem ao redor da Terra, evidências para provar a transformação dos seres vivos.




A Evolução na Biologia



Organismos geram filhos similares a eles, mas podem haver variações devido a dois fatores:


– **Mutações**

(Mudanças aleatórias)



– **Reprodução Sexual**

(Filhos possuem combinações das características de cada pai)



A Evolução na Biologia



Alguns filhos sobrevivem e produzem uma próxima geração, outros não:

- Os organismos adaptados ao ambiente têm chances maiores de sobreviver;
- Ao longo do tempo, as gerações vão se tornando cada vez mais adaptadas pois os organismos mais ajustados/adequados são os que sobrevivem.



Resumo da Teoria de Darwin



O princípio da variação: Os traços (atributos) de espécimes individuais pertencentes a uma população pode variar. Como resultado, os espécimes diferem de cada um outros em algum grau; por exemplo em seu comportamento ou aparência.

O princípio da herança: Alguns traços são consistentemente passados de espécimes para seus descendentes. Como resultado, a prole se assemelha mais aos pais do que se assemelham a espécimes não relacionados.

O princípio da seleção: As populações tipicamente lutam por recursos dentro seu ambiente natural. Os espécimes que possuem características que se adaptam melhor para o ambiente será mais bem sucedido em sobreviver, e também contribuirá com mais descendentes para a próxima geração.

O que são Algoritmos Genéticos?



Inspirando-se na **teoria da evolução natural de Charles Darwin**, uma das mais fascinantes técnicas para a resolução de problemas é a família de algoritmos adequadamente denominada **computação evolutiva**.

Dentro desta família, a mais proeminente e amplamente utilizada ramo é conhecido como **algoritmo genético**.

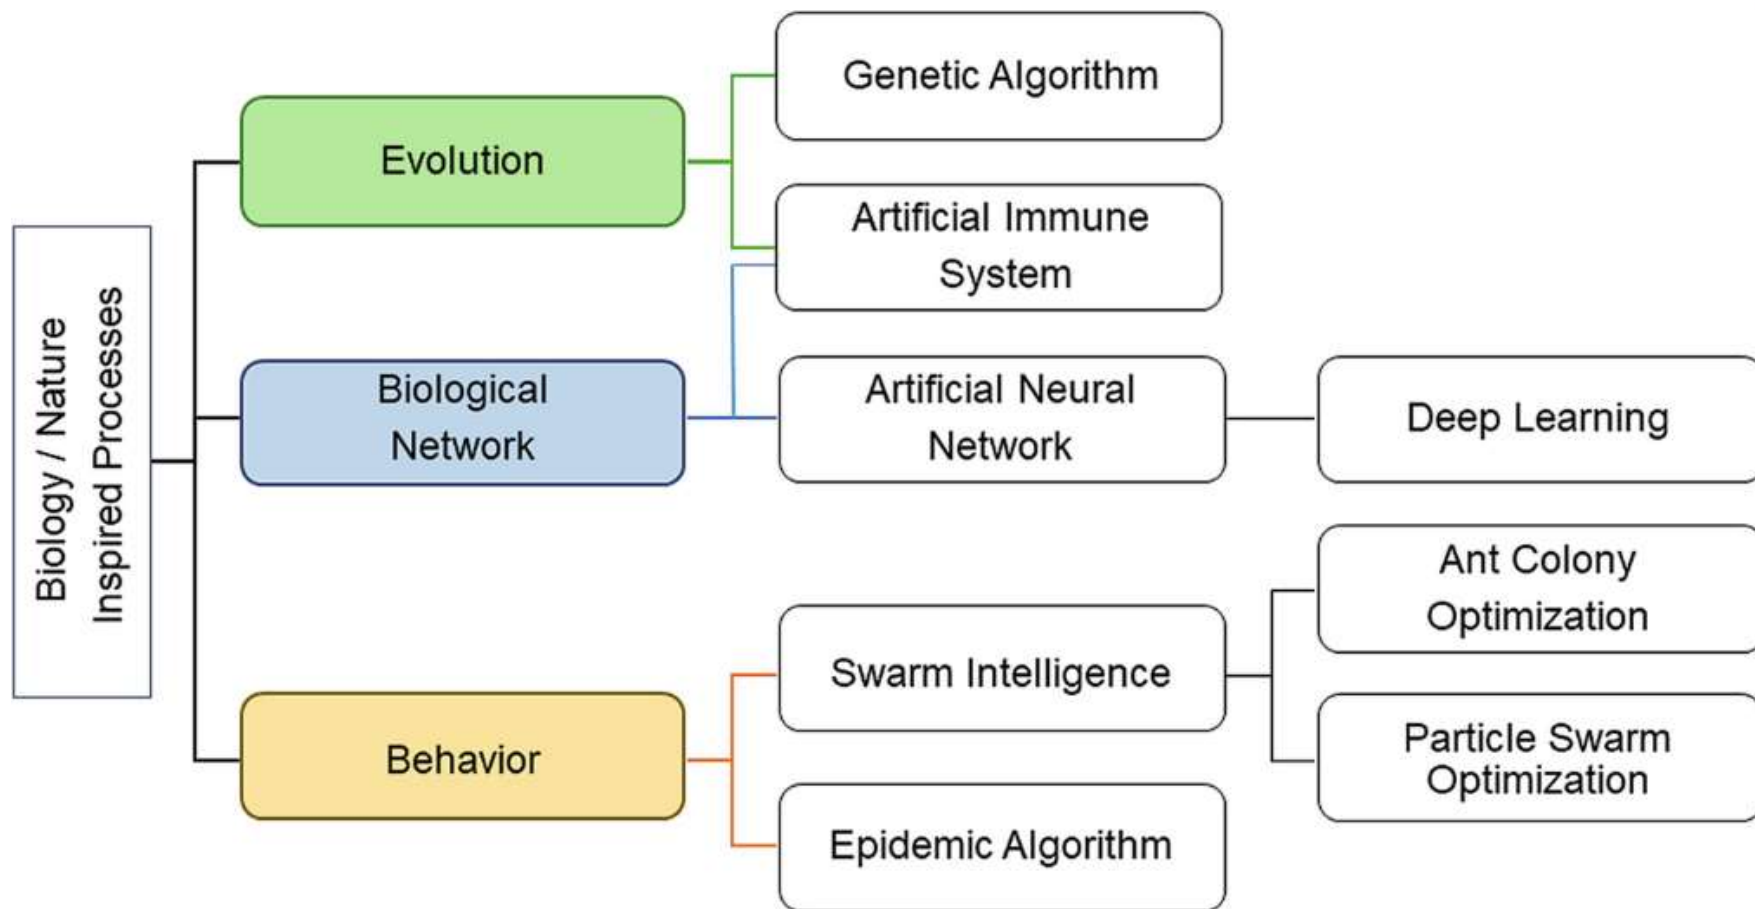
Aqui é o **início** da sua jornada para dominar esta técnica **extremamente poderosa**, mas **extremamente simples**.

Computação Natural



É um ramo da ciência da computação destinado a estudar, compreender e aplicar, **padrões complexos encontrados na natureza**, utilizando-os como base para **resolução de problemas**, desenvolvimento de **novas tecnologias** e **aperfeiçoamento de sistemas já existentes**.

Computação Natural



O que são Algoritmos Genéticos?



Algoritmos genéticos são uma família de **algoritmos de busca** inspirados nos princípios da **evolução na natureza**. Imitando o processo de **seleção natural** e **reprodução**, algoritmos genéticos pode produzir soluções de alta qualidade para vários problemas envolvendo **pesquisa, otimização, e aprendizagem**.

Ao mesmo tempo, sua analogia com a evolução natural permite algoritmos para **superar** alguns dos **obstáculos** que são encontrados pela pesquisa tradicional e algoritmos de otimização, especialmente para problemas com um **grande número de parâmetros** e **representações matemáticas complexas**.

O que são Algoritmos Genéticos?



- Um algoritmo genético (ou GA, *Genetic Algorithm*) é uma técnica de pesquisa usada em computação para encontrar valores verdadeiros ou aproximados soluções para problemas de otimização e pesquisa.
- GAs são uma classe específica de algoritmos que usam técnicas inspiradas em biologia evolutiva, como **herança**, **mutação**, **seleção** e **cruzamento** (também chamado recombinação).

Analogia dos Algoritmos Genéticos



Os algoritmos genéticos buscam encontrar uma **solução ótima** para um determinado problema.

Considerando que a evolução darwiniana mantém **uma população de indivíduos** da espécie, algoritmos genéticos manter **uma população de soluções candidatas**, chamadas indivíduos, para aquele determinado problema.

Analogia dos Algoritmos Genéticos



Essas soluções candidatas são avaliadas iterativamente e usadas para criar uma **nova geração** de soluções. Aqueles que são melhores em resolver este problema têm uma chance maior de serem selecionados e passar suas qualidades para a próxima geração de soluções candidatas.

Assim, a medida que **as gerações passam**, as soluções candidatas **ficam melhores na resolução do problema** em questão.

Genótipos



Na natureza, o melhoramento, a reprodução e a mutação são facilitados através do genótipo – um coleção de genes que são agrupados em cromossomos. Se dois espécimes se reproduzem para criar descendente, cada cromossomo da prole carregará uma mistura de genes de ambos os pais.


Levando esse conceito para os algoritmos genéticos, cada indivíduo é representado por um cromossomo que representa uma coleção de genes. Por exemplo, um cromossomo pode ser expresso como uma cadeia binária, onde cada bit representa um único gene:

0	1	0	1	1	1	0	1	0
---	---	---	---	---	---	---	---	---

População



A qualquer momento, os algoritmos genéticos mantêm uma população de indivíduos – uma coleção de soluções candidatas para o problema em questão. Uma vez que cada indivíduo é representado por algum cromossomo, esta população de indivíduos pode ser vista como um conjunto de tais cromossomos.



Função Objetivo



A cada iteração do algoritmo, os indivíduos são avaliados usando uma função de aptidão (também chamada de função alvo ou objetivo). Esta é a função que buscamos otimizar ou o problema que tentamos resolver.

Indivíduos que alcançam uma melhor pontuação de condicionamento físico representam melhores soluções e são mais propensos para ser escolhidos para reproduzir e ser representados na próxima geração.

Seleção



Depois de calcular a aptidão de cada indivíduo da população, um processo de seleção é usado para determinar quais dos indivíduos da população conseguirão se reproduzir e criar a prole que formará a próxima geração.


Esse processo seletivo é baseado na pontuação de aptidão dos indivíduos. Aqueles com maiores valores de pontuação são mais prováveis de serem escolhidos e passar seu material genético para o próximo geração.

Indivíduos com baixos valores de aptidão física ainda podem ser escolhidos, mas com menor probabilidade. Dessa forma, seu material genético não é completamente excluído.



Cruzamento

Para criar um par de novos indivíduos, dois pais geralmente são escolhidos a partir do atual geração, e partes de seus cromossomos são trocados (cruzados) para criar dois novos cromossomos representando a prole. Essa operação é chamada de cruzamento, ou recombinação.






Cruzamento

O objetivo do operador de mutação é atualizar periodicamente e aleatoriamente o população, introduzir novos padrões nos cromossomos e incentivar a busca em áreas não mapeadas do espaço da solução.

Uma mutação pode se manifestar como uma mudança aleatória em um gene. Mutações são implementadas como alterações aleatórias em um ou mais valores cromossômicos, por exemplo:



Algoritmos Genéticos x Algoritmos Tradicionais



As principais características dos algoritmos genéticos que os distinguem dos tradicionais algoritmos são:

- Mantém uma população de soluções
- Utilizam uma representação genética das soluções
- Utilizam uma função de aptidão (fitness) para alcançar o resultado.
- Exibem um comportamento probabilístico.

Vantagens



- Capacidade de otimização global
- Lidam com problemas de representação matemática complexa.
- Lidam com problemas que não possuem representação matemática.
- Resiliência ao ruído.
- Suportam paralelismo e processamento distribuído.
- Adequação ao aprendizado contínuo.

Limitações



- Necessitam definições especiais.
- A necessidade de ajuste de hiperparâmetros.
- Operações intensas durante computação.
- Risco de convergência prematura.
- Nenhuma solução garantida.

Aplicações Recomendadas



- Problemas com representação matemática complexa.
- Problemas sem representação matemática.
- Problemas envolvendo um ambiente barulhento.
- Problemas envolvendo um ambiente que muda com o tempo.

Aplicações para Atendimento a Restrições



Problemas de satisfação de restrição são uma variante de problemas de busca, em que o objetivo é atender, da melhor forma possível a uma série de restrições ou limitações.

Se formos capaz de traduzir as várias violações de restrições em custo e, em seguida, esforçar-se para minimizar o custo, resolver um problema de satisfação de restrição pode se assemelhar a resolver um problema de busca.

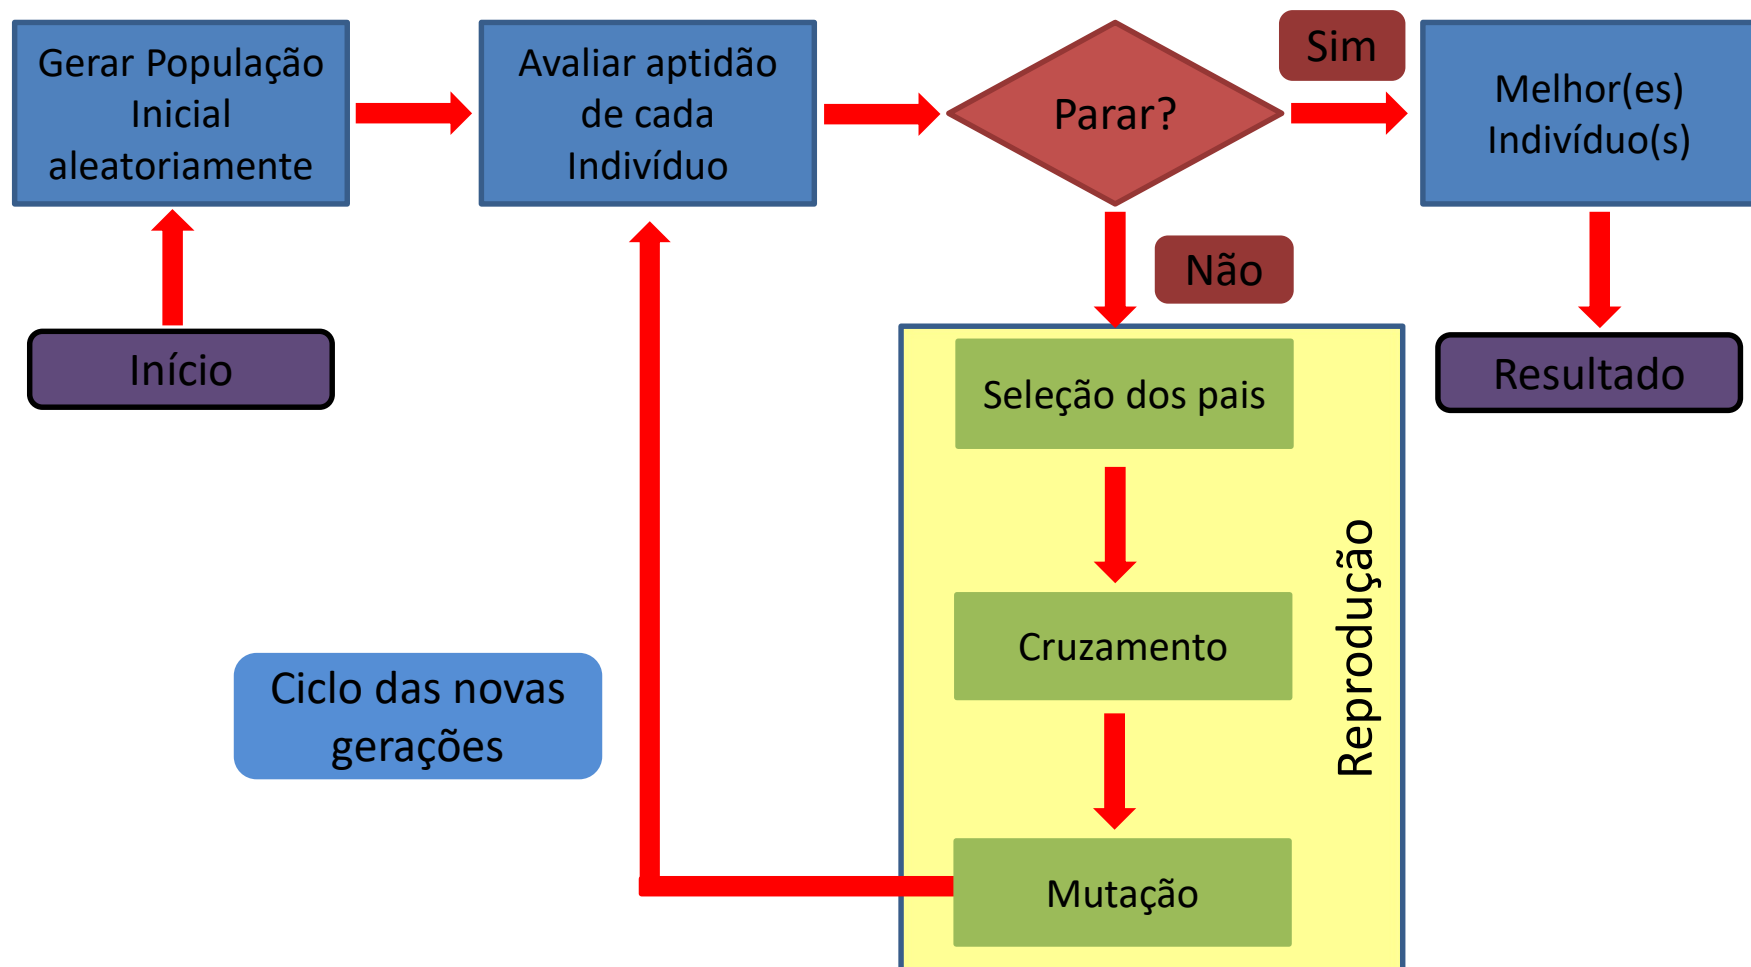

Aplicações para Atendimento a Restrições



Assim como os problemas de otimização combinatória, os problemas de atendimento a restrições têm importância aplicações em campos como inteligência artificial, pesquisa operacional e atendimento a padrões.

Uma melhor compreensão desses problemas pode ajudar na resolução de vários tipos de problemas que podem parecer alheios à primeira vista. Problemas de atendimento de restrições frequentemente apresentam alta complexidade, o que torna os algoritmos genéticos um candidato adequado para resolução deles.

AG Básico






Exemplo

Máximo de uma Função (Exemplo de Problema)



Dada uma função matemática, precisamos encontrar os valores das entradas que maximizam esta saída (máximo global).



$$y = a_1x_1 + a_2x_2 + a_3x_3 + a_4x_4 + a_5x_5 + a_6x_6$$

$$a = [4, 10, -8, 5, 0, -3]$$

Máximo de uma Função (Detalhamento)



Encontrar os valores de entrada que maximizam esta função no intervalo $[-3.0, 3.0]$.

Definição de indivíduo (cromossomo).

Definição das entradas como os genes dos cromossomos.

Constant	4	10	-8	0	5	-3
	Genes					
Item	1	2	3	4	5	6
input	-0,20	1,36	-2,66	2,27	2,71	-1,12

Quant. máx. de indivíduos por geração – 8.

Quant. Máx. de gerações – 50.

Máximo de uma Função (Detalhamento)



1- Gerar primeira população aleatoriamente.

		Genes					
		1	2	3	4	5	6
Cromossomos	1	-0,20	1,36	-2,66	2,27	2,71	-1,12
	2	1,66	1,82	2,84	-2,61	-1,93	2,79
	3	1,38	2,26	-0,91	2,31	0,56	0,46
	4	-1,18	-2,74	0,85	-0,96	0,28	-0,07
	5	-2,07	1,07	-1,67	-2,31	1,69	-0,23
	6	-2,87	2,31	0,19	-2,72	0,18	0,07
	7	2,59	-1,28	2,86	2,80	-1,17	0,42
	8	0,94	2,88	-2,50	0,03	-0,37	-0,41

Máximo de uma Função (Detalhamento)



2 – Testar a população quando à aptidão (fitness)

Função-objetivo (Fitness) – Maximizar o valor da equação.

A equação matemática que expressa esta função é:

$$Fitness = \sum_{i=1}^n w_i x_i$$

Onde,

n = tamanho do cromossomo

w_i = i ésima constante

x_i = i ésima entrada (gene do indivíduo)

Máximo de uma Função (Detalhamento)



2 – Testar a população quando à aptidão (fitness)

		Genes						Fitness
		1	2	3	4	5	6	Total
Cromossomos	1	-0,20	1,36	-2,66	2,27	2,71	-1,12	50,99
	2	1,66	1,82	2,84	-2,61	-1,93	2,79	-15,90
	3	1,38	2,26	-0,91	2,31	0,56	0,46	36,82
	4	-1,18	-2,74	0,85	-0,96	0,28	-0,07	-37,31
	5	-2,07	1,07	-1,67	-2,31	1,69	-0,23	24,92
	6	-2,87	2,31	0,19	-2,72	0,18	0,07	10,79
	7	2,59	-1,28	2,86	2,80	-1,17	0,42	-32,43
	8	0,94	2,88	-2,50	0,03	-0,37	-0,41	51,94

Máximo de uma Função (Detalhamento)



3 – Selecionar os X melhores pais para reprodução de acordo com a melhor aptidão

		Genes						Fitness
		1	2	3	4	5	6	Total
Cromossomos	8	0,94	2,88	-2,50	0,03	-0,37	-0,41	51,94
	1	-0,20	1,36	-2,66	2,27	2,71	-1,12	50,99
	3	1,38	2,26	-0,91	2,31	0,56	0,46	36,82
	5	-2,07	1,07	-1,67	-2,31	1,69	-0,23	24,92
	6	-2,87	2,31	0,19	-2,72	0,18	0,07	10,79
	2	1,66	1,82	2,84	-2,61	-1,93	2,79	-15,90
	7	2,59	-1,28	2,86	2,80	-1,17	0,42	-32,43
	4	-1,18	-2,74	0,85	-0,96	0,28	-0,07	-37,31



Máximo de uma Função (Detalhamento)



4 – Realiza o cruzamento entre os pais com uma taxa X de reprodução viável, gerando filhos com pedaços de genes dos pais

	Genes					
	1	2	3	4	5	6
8	0,94	2,88	-2,50	0,03	-0,37	-0,41
1	-0,20	1,36	-2,66	2,27	2,71	-1,12
Filho 1	0,94	2,88	-2,50	2,27	2,71	-1,12
Filho 2	-0,20	1,36	-2,66	0,03	-0,37	-0,41


Máximo de uma Função (Detalhamento)



5 – Realiza a mutação dos filhos com uma taxa X de mutação, gerando alterações em um ou mais genes.

	Genes							
	1	2	3	4	5	6		
Filho 1	0,94	2,88	-2,50	2,27	2,71	-1,12		
Filho 2	-0,20	1,36	-2,66	0,03	-0,37	-0,41		
Filho 1	0,94	2,88	-2,50	2,27	2,71	2,60	Mutação no gene 6	
Filho 2	-0,20	1,36	1,50	0,03	-0,37	-0,41	Mutação no gene 3	

Máximo de uma Função (Detalhamento)



6 – Refaz teste de aptidão e checa se a quantidade de gerações ou critério de parada foi atingido.

Se a quantidade de gerações for menor que a máxima permitida ou o critério não foi atingido, reinicia o processo a partir do item 3. Se atingir quaisquer um dos critérios, a busca é encerrada.

A Mochila Valiosa



Como Implementar este sistema
em Python?





Desafio

(Adaptar o algoritmo anterior para o novo problema)

A Mochila Valiosa (Exemplo de Problema)



Um ladrão entra em uma loja carregando mochila (bolsa) que pode transportar 35 kg de peso. A loja possui 10 itens, cada um com um peso e preço específicos.

Agora, o dilema do ladrão é fazer uma seleção de itens que maximize o valor (ou seja, preço total) sem exceder o peso da mochila. Temos que ajudar o ladrão a fazer a seleção.



A Mochila Valiosa (Aplicações)



É um problema de otimização combinatória (NP-Completo).
Estudado por mais de um século (desde ~1897).
Resolvido por variados algoritmos.

Aplicações:

- Gravação de arquivos desperdiçando o mínimo espaço em cada mídia;
- Corte e empacotamento;
- Carregamento de veículos;
- Alocação de recursos em geral;
 - Naves espaciais.

A Mochila Valiosa (Detalhamento)



Itens da casa com seus respectivos valores e pesos.
(01 unidade da cada)

Item	1	2	3	4	5	6	7	8	9	10
Valor	1200	200	300	1000	1500	800	2000	40	500	3000
Peso	10	8	2	4	15	5	3	1	12	9

A Mochila Valiosa (Detalhamento)



Definição de indivíduo (cromossomo).

Definição dos itens como os genes dos cromossomos.

Código

0 = não leva item , 1 = leva item.

Cromossomo - 1010001010

Item	1	2	3	4	5	6	7	8	9	10
Cromossomo	1	0	1	0	0	0	1	0	1	0

Quant. máx. de indivíduos por geração – 8.

Quant. Máx. de gerações – 50.

A Mochila Valiosa (Solução)



1- Gerar primeira população aleatoriamente.

		Genes									
		1	2	3	4	5	6	7	8	9	10
Cromossomos	1	0	1	0	1	1	0	0	1	1	1
	2	1	1	1	1	0	1	1	1	0	0
	3	0	1	0	0	0	0	1	1	0	1
	4	0	0	1	0	1	1	0	0	0	0
	5	0	0	1	1	0	0	0	0	0	1
	6	0	1	0	1	1	0	1	0	0	0
	7	1	1	1	0	0	0	1	0	1	0
	8	0	0	0	0	1	1	1	0	0	0

A Mochila Valiosa (Detalhamento)



2 – Testar a população quando à aptidão (fitness)

Função-objetivo (Fitness) – Maximizar o valor total dos itens.

Restrição – O peso total dos itens ≤ 35 Kg.

A equação matemática que expressa esta função é:

$$fitness = \sum_{i=1}^n c_i v_i; \text{ if } \sum_{i=1}^n c_i w_i \leq kw$$

Onde,

n = tamanho do cromossomo

c_i = *i*ésimo gene

v_i = *i*ésimo valor

w_i = *i*ésimo peso

kw = peso da mochila

$fitness = 0; \text{ otherwise}$

A Mochila Valiosa (Detalhamento)



2 – Testar a população quando à aptidão (fitness)

		Genes										Fitness	Restrição	
		1	2	3	4	5	6	7	8	9	10	Valor	Peso	
Cromossomos	1	0	1	0	1	1	0	0	1	1	1	0	49	6240
	2	1	1	1	1	0	1	1	1	0	0	5540	33	
	3	0	1	0	0	0	0	1	1	0	1	5240	21	
	4	0	0	1	0	1	1	0	0	0	0	2600	22	
	5	0	0	1	1	0	0	0	0	0	1	4300	15	
	6	0	1	0	1	1	0	1	0	0	0	4700	30	
	7	1	1	1	0	0	0	1	0	1	0	4200	35	
	8	0	0	0	0	1	1	1	0	0	0	4300	23	

A Mochila Valiosa (Detalhamento)



3 – Selecionar os X melhores pais para reprodução de acordo com a melhor aptidão

		Genes										Fitness	Restrição
		1	2	3	4	5	6	7	8	9	10	Valor	Peso
Cromossomos	2	1	1	1	1	0	1	1	1	0	0	5540	33
	3	0	1	0	0	0	0	1	1	0	1	5240	21
	6	0	1	0	1	1	0	1	0	0	0	4700	30
	5	0	0	1	1	0	0	0	0	0	1	4300	15
	8	0	0	0	0	1	1	1	0	0	0	4300	23
	7	1	1	1	0	0	0	1	0	1	0	4200	35
	4	0	0	1	0	1	1	0	0	0	0	2600	22
	1	0	1	0	1	1	0	0	1	1	1	0	49

A Mochila Valiosa (Detalhamento)



4 – Realiza o cruzamento entre os pais com uma taxa X de reprodução viável, gerando filhos com pedaços de genes dos pais

	Genes									
	1	2	3	4	5	6	7	8	9	10
Pai 1	1	1	1	1	0	1	1	1	0	0
Pai 2	0	1	0	0	0	0	1	1	0	1
Filho 1	1	1	1	1	0	0	1	1	0	1
Filho 2	0	1	0	0	0	1	1	1	0	0

A Mochila Valiosa (Detalhamento)



5 – Realiza a mutação dos filhos com uma taxa X de mutação, gerando alterações em um ou mais genes.

	Genes											
	1	2	3	4	5	6	7	8	9	10		
Filho 1	1	1	1	1	0	1	1	1	0	0		
Filho 2	0	1	0	0	0	0	1	1	0	1		
Filho 1	1	1	1	1	0	0	1	1	0	0	Mutação no gene 6	
Filho 2	0	1	1	0	0	0	1	1	0	1	Mutação no gene 3	


A Mochila Valiosa (Detalhamento)



6 – Refaz teste de aptidão e checa-se a quantidade de gerações ou critério de parada.

Se a quantidade de gerações for menor que a máxima permitida ou o critério não foi atingido, reinicia o processo a partir do item 3. Se atingir quaisquer um dos critérios, a busca é encerrada.




Referências



SHEPPARD, Clinton. Genetic Algorithms with Python. . Leanpub. 2016.

WIRSANSKY, Eyal. Hands-on Genetic Algorithms with Python. Packt Publishing. 2020

HUNT, J.; A Beginners Guide to Python 3 Programming. São Paulo, Switzerland: Springer, 2020.





CEAR
CENTRO DE ENERGIAS
ALTERNATIVAS E RENOVÁVEIS
UNIVERSIDADE FEDERAL DA PARAÍBA



Obrigado!

Professor: Flavio da Silva Vitorino Gomes
flavio@cear.ufpb.br